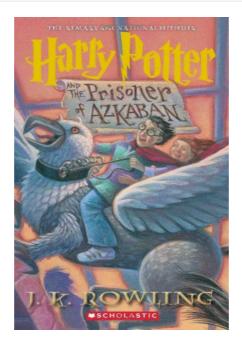
# 9.Azkaban调度器

## 1. Azkaban介绍

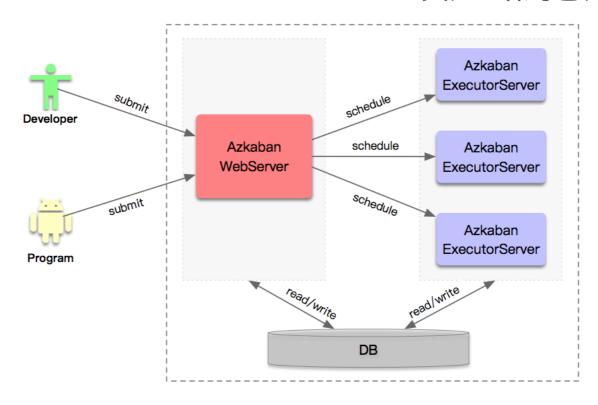




# **Azkaban**

Azkaban是由linkedin(领英)公司推出的一个批量工作流任务调度器,用于在一个工作流内以一个特定的顺序运行一组工作和流程。Azkaban使用job配置文件建立任务之间的依赖关系,并提供一个易于使用的web用户界面维护和跟踪你的工作流。

- 提供功能清晰,简单易用的Web UI界面
- 提供job配置文件快速建立任务和任务之间的依赖关系
- 提供模块化和可插拔的插件机制,原生支持command、Java、Hive、Pig、Hadoop
- 基于Java开发,代码结构清晰,易于二次开发



mysql服务器:存储元数据,如项目名称、项目描述、项目权限、任务状态、SLA规则等

AzkabanWebServer:对外提供web服务,使用户可以通过web页面管理。职责包括项目管理、权限授权、任务调度、监控executor。

AzkabanExecutorServer:负责具体的工作流的提交、执行。

## 2. 安装部署

上传安装包,并解压

```
tar -zxvf azkaban-solo-server-0.1.0-SNAPSHOT.tar.gz -C /opt/server
```

修改conf目录中的azkaban.properties文件,修改时区为Asia/Shanghai

vim conf/azkaban.properties

default.timezone.id=Asia/Shanghai

修改plugins/jobtypes目录中的commonprivate.properties文件,关闭内存检查,azkaban默认需要3G的内存,剩余内存不足则会报异常。

vim plugins/jobtypes/commonprivate.properties

添加:

memCheck.enabled=false

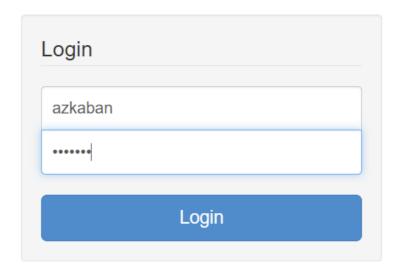
启动验证,启动/关闭必须进到azkaban-solo-server-0.1.0-SNAPSHOT/目录下

bin/start-solo.sh

AzkabanSingleServer(对于Azkaban solo-server模式,Exec Server和Web Server在同一个进程中)

```
[root@server azkaban-solo-server-0.1.0-SNAPSHOT]# jps
7639 Jps
7609 AzkabanSingleServer
[root@server azkaban-solo-server-0.1.0-SNAPSHOT]#
```

登录web页面,通过浏览器访问控制台,http://server:8081,默认用户名密码azkaban



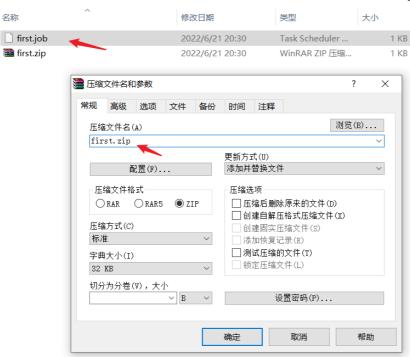
### 3. 基本使用

### 3.1 执行单任务

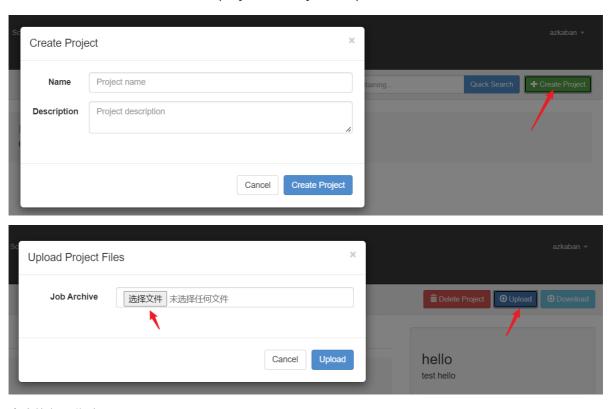
创建 job 描述文件,命名为first.job,加入以下内容:

```
#first.job
type=command
command=echo 'hello world'
```

将 job 资源文件打包成 zip 文件,Azkaban 上传的工作流文件只支持 zip 文件。zip 应包含 .job 运行作业所需的文件,作业名称在项目中必须是唯一的。

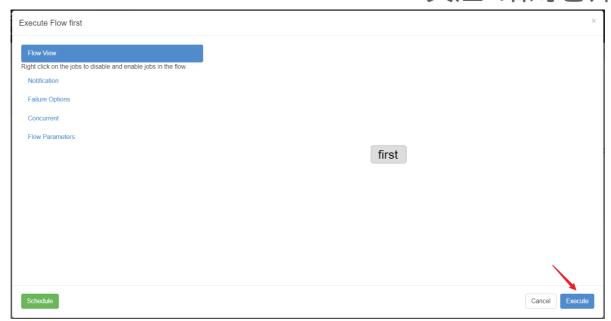


#### 通过 azkaban 的 web 管理平台创建 project 并上传 job 的 zip 包



#### 点击执行工作流





#### 点击继续



#### 执行成功



#### 点击右侧的Details按钮,可以查看运行日志

```
21-06-2022 20:45:50 CST first INFO - Starting job first at 1655815550572
21-06-2022 20:45:50 CST first INFO - azkaban.webserver.url property was not set
21-06-2022 20:45:50 CST first INFO - job JVM args: -Dazkaban.flowid=first -Dazkaban.execid=2 -Dazkaban.jobid=first
21-06-2022 20:45:50 CST first INFO - user.to.proxy property was not set, defaulting to submit user azkaban
21-06-2022 20:45:50 CST first INFO - Building command job executor.
21-06-2022 20:45:50 CST first INFO - 1 commands to execute.
21-06-2022 20:45:50 CST first INFO - cwd=/opt/server/azkaban-solo-server-0.1.0-SNAPSHOT/executions/2
21-06-2022 20:45:50 CST first INFO - effective user is: azkaban
21-06-2022 20:45:50 CST first INFO - Command: echo 'hello world'
21-06-2022 20:45:50 CST first INFO - Environment variables: {JOB_OUTPUT_PROP_FILE=/opt/server/azkaban-solo-server-0.1.0-SNAPSHOT/executions/2
21-06-2022 20:45:50 CST first INFO - Working directory: /opt/server/azkaban-solo-server-0.1.0-SNAPSHOT/executions/2
21-06-2022 20:45:50 CST first INFO - working directory: /opt/server/azkaban-solo-server-0.1.0-SNAPSHOT/executions/2
21-06-2022 20:45:50 CST first INFO - output properties file=/opt/server/azkaban-solo-server-0.1.0-SNAPSHOT/executions/2
21-06-2022 20:45:50 CST first INFO - Finishing job first at 1655815550590 with status SUCCEEDED
```

### 3.2 多任务执行

创建有依赖关系的多个任务, 首先创建start.job

```
#start.job
type=command
command=touch /opt/server/web.log
```

创建a.job, 依赖start.job

```
#a.job
type=command
dependencies=start
command=echo "hello a job"
```

创建b.job, 依赖 start.job

```
#b.job
type=command
dependencies=start
command=echo "hello b job"
```

创建end.job 依赖 a.job 和 b.job

```
#end.job
type=command
dependencies=a,b
command=echo "end job"
```

将所有 job 资源文件打到一个 zip 包中,在 azkaban 的 web 管理界面创建工程并上传 zip 包



#### 执行



查看运行结果

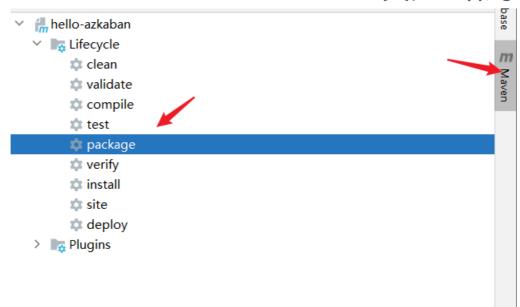
Name	Туре	Timeline	Start Time	End Time	Elapsed	Status	Details
start	command		2022-06-21 20:57 44s	2022-06-21 20:57 44s	0 sec	Success	Details
b	command		2022-06-21 20:57 44s	2022-06-21 20:57 44s	0 sec	Success	Details
a	command		2022-06-21 20:57 44s	2022-06-21 20:57 44s	0 sec	Success	Details
end	command		2022-06-21 20:57 44s	2022-06-21 20:57 44s	0 sec	Success	Details

# 4. 调度Java程序

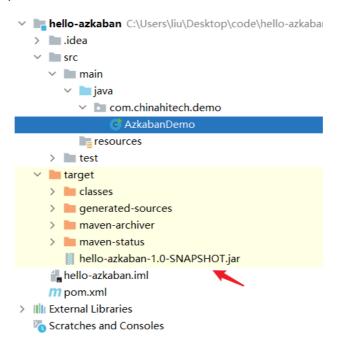
编写 java 程序

```
package com.chinahitech.demo;
import java.io.*;
import java.net.URL;
import java.net.URLConnection;
public class AzkabanDemo {
    public static void main(String[] args) throws IOException {
       // 构造URL
       URL url = new
URL("https://www.baidu.com/img/PCtm_d9c8750bed0b3c7d089fa7d55720d6cf.png");
       // 打开连接
       URLConnection con = url.openConnection();
       // 输入流
       InputStream is = con.getInputStream();
       // 1K的数据缓冲
       byte[] bs = new byte[1024];
       // 读取到的数据长度
       int len;
       // 输出的文件流
       File sf=new File("/opt/server/data/logo.png");
       OutputStream os = new FileOutputStream(sf);
       // 开始读取
       while ((len = is.read(bs)) != -1) {
           os.write(bs, 0, len);
       }
       // 完毕,关闭所有链接
       os.close();
       is.close();
   }
}
```

打包程序



#### 将job上传至服务器的/opt/server/lib目录中



#### 编写 job 文件, azkabanJava.job

```
#azkabanJava.job
type=javaprocess
java.class=com.chinahitech.demo.AzkabanDemo
classpath=/opt/server/lib/*
```

将 job 文件打成 zip 包,通过 azkaban 的 web 管理平台创建 project 并上传 job 压缩包,启动执行该 job

# 5. 调度HDFS、MR任务

创建 job 描述文件 hdfs.job

```
#hdfs.job
type=command
command=/opt/server/hadoop-3.1.0/bin/hadoop fs -mkdir /azkaban
```

通过 azkaban 的 web 管理平台创建 project 并上传 job 压缩包,运行查看结果

创建job描述文件,及mr程序jar包(使用hadoop自带的example jar)

```
# mr.job
type=command
command=/opt/server/hadoop-3.1.0/bin/hadoop jar /opt/server/hadoop-
3.1.0/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.1.0.jar pi 2 10
```

### 6. 调度Hive 脚本任务

创建 job 描述文件和 hive 脚本

创建HiveSQL脚本,命名为:web\_access.sql

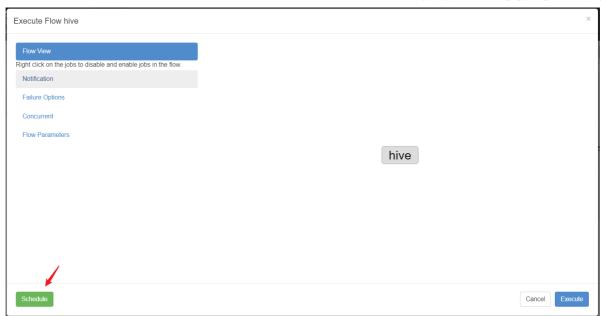
```
use default;
DROP TABLE IF EXISTS access_log_content;
CREATE TABLE access_log_content (
          content STRING
);
DROP TABLE IF EXISTS ip_content;
CREATE TABLE ip_content (
          content STRING
);
```

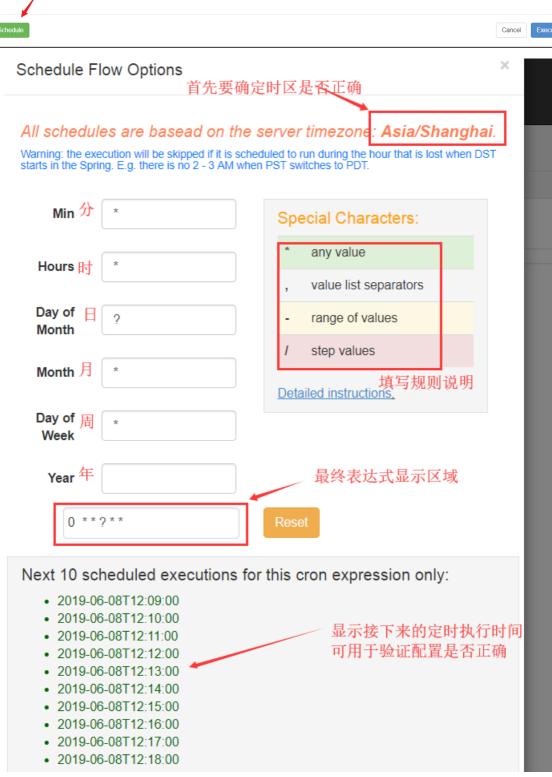
将脚本文件上传至服务器: /opt/server/data/

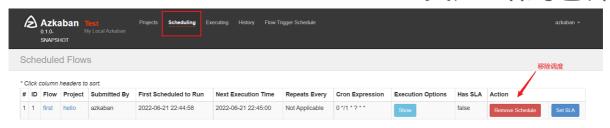
创建Job 描述文件: hive.job

```
#hive job
type=command
command=/opt/server/apache-hive-3.1.2-bin/bin/hive -f /opt/data/web_access.sql
```

### 7. 定时任务调度







# 8. 定时调度Sqoop作业

#### 配置免密执行作业

在sqoop的conf目录下修改sqoop-site.xml文件

将密码输出到mysqlpwd.pwd文件中,并上传至hdfs

```
echo -n "root" > mysqlpwd.pwd
./hadoop dfs -mkdir -p /mysql/pwd
./hadoop dfs -put ./mysqlpwd.pwd /mysql/pwd
./hadoop dfs -chmod 400 /mysql/pwd/mysqlpwd.pwd
```

### 创建Sqoop作业

创建Sqoop作业,使用-password-file代替-password就是读取之前上传到hdfs上的密码文件来连接mysql

```
./sqoop job --create job_test4 \
-- import \
--connect jdbc:mysql://192.168.80.100:3306/mydb \
--username root \
--password-file /mysql/pwd/mysqlpwd.pwd \
--table emp --m 1 \
--target-dir /emp \
--incremental append \
--check-column empno \
--last-value 0
```

上面代码使用的是增量导入,使用sqoop job这种方法,在进行增量导入后就会记忆你的last-value的值,这样你下次运行时就不需要手动更新last-value的值。

创建作业时,如果出现java.lang.NoClassDefFoundError: org/json/JSONObject,是因为sqoop缺少java-json.jar包,将jar包放入sqoop的lib目录下即可

## 创建sqoop.job

```
# sqoop.job
type=command
command=/opt/server/sqoop-1.4.7.bin_hadoop-2.6.0/bin/sqoop job --exec job_test4
```